

Foraging multi-agente con memoria externa en grillas: un estudio experimental

Jeremías Figueiredo Paschmann

Francisco Nattero

Juan Kaplan

Proyecto final de Aprendizaje por Refuerzo

Resumen

Este informe reconstruye una serie de experimentos de aprendizaje por refuerzo multi-agente en un entorno de foraging con memoria externa discreta. La tarea exige que agentes con observación local encuentren fuentes de comida, transporten unidades al hub y sostengan ciclos de entrega bajo ejecución descentralizada. La evidencia muestra que el progreso no se explica por aumentar la cantidad de bits de comunicación, sino por una secuencia de cambios más concreta: corregir el contrato de la tarea, hacer aprendible la señal de crédito, aumentar la cobertura con más agentes y reemplazar el crítico centralizado plano por una arquitectura espacial. En 25x25 se obtuvo una política que completa las 23 entregas bajo movimiento muestreado. En 50x50, la frontera más fuerte aparece dentro de la familia con crítico `strided_cnn`, donde una política de 60 hormigas alcanza una fracción de entrega cercana a 0.99 en evaluación seleccionada, aunque esa mejora queda confundida con cantidad de agentes, identidades, selección de checkpoints y escritura casi saturada. En 250x250, el resultado más importante es negativo: el retorno moldeado y la actividad de bytes pueden crecer aunque las entregas reales sigan siendo nulas. Para evitar una historia retrospectiva demasiado limpia, se auditó el checkout completo y se clasificaron commits, refs, notebooks, configuraciones, corridas locales, carpetas W&B, logs y artefactos por familia experimental. La conclusión es deliberadamente acotada: el sistema aprendió foraging cooperativo útil y escaló a escenarios 50x50 exigentes, pero todavía no demuestra causalmente comunicación emergente mediante la memoria por bytes.

Contrato	⇒	Crédito	⇒	Crítico	⇒	Conclusión
entregas reales con fuentes agotables		moldeado de distancia, más agentes y evaluación muestreada		crítico espacial, checkpoints seleccionados y auditoría por familia		foraging fuerte sin prueba causal de comunicación por bytes

Figura 1: Resumen gráfico del argumento central. La lectura del proyecto va desde la definición correcta de la tarea hasta la interpretación causal de los resultados: las métricas de entrega explican el desempeño, la arquitectura del crítico explica parte del salto 50x50 y las ablaciones de memoria delimitan lo que todavía no puede afirmarse.

1. Introducción

El problema que se estudia es simple de describir y difícil de aprender: varios agentes locales deben encontrar fuentes de comida, recoger unidades de comida y volver al hub para entregarlas. Cada agente observa solo una vecindad pequeña y ejecuta una política compartida. Durante el entrenamiento se permite un crítico centralizado, pero durante el despliegue la política sigue siendo local. Esta separación corresponde al marco de entrenamiento centralizado con ejecución descentralizada, usado en algoritmos multi-agente como MAPPO y MADDPG [7, 2].

La motivación no es solo maximizar una métrica. La pregunta relevante es semántica: qué comportamiento aparece cuando se combinan búsqueda local, memoria en el ambiente y presión de entregar comida. Un resultado útil no debería ser únicamente “alto reward”, sino que debería mostrar ciclos completos de foraging, retorno al hub, uso razonable del espacio y robustez bajo mapas aleatorios. Por eso el análisis separa tres capas que suelen mezclarse. La primera es el desempeño, medido por comida entregada, tasa de éxito y eficiencia temporal. La segunda es el mecanismo, es decir, los cambios de entorno, política, crítico o evaluación que hicieron posible ese desempeño. La tercera es el comportamiento visible: si los videos muestran búsqueda, transporte y retorno, o si solo muestran movimiento local sostenido por retorno moldeado.

El trabajo se ubica cerca de MAPPO [7], PPO [5], GAE [4] y aprendizaje de comunicación multi-agente como CommNet y DIAL [6, 1]. La diferencia práctica es que aquí la comunicación no es un canal diferenciable directo entre agentes. Es una memoria discreta escrita en celdas del ambiente. Eso hace que la atribución causal sea más difícil: ver bytes no-cero no implica que esos bytes estén coordinando la política.

2. Entorno experimental

La semántica del entorno cambió de manera decisiva durante el proyecto. En la versión relevante para este informe, `food_count` no significa posiciones independientes de comida. Significa mordidas totales. `food_sources` controla cuántas fuentes concentran esas mordidas y cada fuente se agota. La recompensa cruda principal es la entrega en el hub: una unidad entregada da +1. La recogida puede tener bonus de moldeado en algunas corridas, pero no es el objetivo final.

Esta distinción cambia la interpretación de todos los resultados. Un resultado de 23/23 en 25x25 no significa visitar 23 puntos aislados. Significa completar 23 entregas desde 6 fuentes agotables. Cambiar `food_sources` con `food_count` fijo cambia la geometría de la tarea, la repetición de rutas y la dificultad de redescubrir fuentes.

Tabla 1: Variables semánticas que no deben tratarse como detalles menores.

Variable	Interpretación para el informe
<code>food_count</code>	Total de unidades que pueden ser entregadas. Es el denominador natural de la fracción entregada.
<code>food_sources</code>	Número de fuentes agotables. A igual <code>food_count</code> , menos fuentes implican fuentes más densas.
<code>sampledmovement</code>	Despliegue estocástico de movimiento. Muchas políticas buenas viven en la distribución, no en el argmax.
<code>greedymovement</code>	Despliegue determinista. Es más estricto y frecuentemente empeora el retorno.
<code>critic_architecture</code>	Arquitectura del crítico centralizado. Cambia la señal de valor durante PPO aunque el actor local no reciba observación global en ejecución.
<code>write_while_moving</code>	Permite escribir mientras se mueve. Cambia el costo y la frecuencia efectiva de escritura.

3. Método

La base de entrenamiento es PPO multi-agente con política compartida, ventajas estimadas con GAE y un crítico centralizado. PPO optimiza una función objetivo recortada que evita

cambios demasiado grandes de política [5]. MAPPO aplica esta idea a agentes cooperativos y suele usar un crítico centralizado para estabilizar el aprendizaje [7]. En este proyecto, el actor debe ejecutar con información local; el crítico puede ver más información durante entrenamiento.

La arquitectura del crítico es una frontera causal del proyecto. Las líneas tempranas y el 50x50 eficiente inicial usaron un crítico `mlp` plano sobre observaciones centralizadas aplanadas. La línea posterior de proximidad y full-layout en 50x50 introdujo `strided_cnn`, un crítico espacial que procesa planos de grilla y rasgos de entidades. Los diagnósticos 250x250 pertenecen a una familia distinta, donde aparecen críticos `resnet_cnn`, `strided_cnn` y `set_cnn` bajo contratos de escala y reset diferentes. Esta separación impide presentar los resultados como si todos fueran puntos de una única curva de comunicación.

Esta separación es central. Si una corrida 50x50 mejora después de pasar de `mlp` a `strided_cnn`, no se puede atribuir la mejora solamente a más hormigas, más bits, fuentes más densas o escritura compartida. El crítico cambió el problema de crédito que PPO resuelve durante entrenamiento.

Cada corrida se leyó como un conjunto de artefactos, no como una captura aislada. El contrato de tarea queda en `experiments/*.json` o en el notebook que arma la corrida. La traza temporal queda en `metrics.jsonl`. El cierre queda en `summary.json`. Los pesos quedan en checkpoints finales y, cuando se activó selección, en checkpoints “best”. Los videos de W&B o locales sirven como evidencia cualitativa sincronizada con updates o checkpoints, pero no reemplazan las métricas de tarea.

Esta trazabilidad importa porque “best checkpoint” no significa “último checkpoint”. El runner puede seleccionar por una métrica de entrenamiento o de evaluación, en modo máximo o mínimo, y las evaluaciones pueden usar semillas desplazadas, layouts barajados y modos de acción como movimiento muestreado con escritura greedy. Por eso el informe separa cuatro niveles: configuración, curva de entrenamiento, evaluación seleccionada y video. El sitio web que acompaña al informe agrega una quinta capa de inspección: un visor de artefactos y un simulador interactivo del actor 50x50 exportado a JavaScript. Ese simulador permite cambiar tamaño de grilla, cantidad de hormigas, unidades de comida, posiciones de fuente y paleta visual, pero sigue siendo ejecución solo-actor: sin crítico, sin JAX y sin entrenamiento. Sirve para inspeccionar una política local ya entrenada, no para crear una nueva corrida comparable.

La misma regla se aplica a los videos nuevos del sitio. Cada video debe indicar de qué checkpoint viene, qué modo de acción usa y si el entorno cambia el contrato original. En mapas con paredes, las paredes se pasan al actor por el canal local de borde/obstáculo, implementado como `local_border=max(border, obstacles)`. Por lo tanto, un fracaso en laberinto no significa automáticamente que el actor no observe paredes; puede significar que una política entrenada en foraging abierto no aprendió el comportamiento necesario para navegar pasillos internos.

3.1. Auditoría de árbol y ramas visibles

Para que el informe y el sitio no cuenten solo los resultados más presentables, se generó un ledger exhaustivo en `docs/planning/experiment-tree-audit`. La auditoría tomó como base el checkout limpio en 21d3cdf y clasificó cada commit alcanzable, cada ref visible, cada configuración actual, cada notebook, cada directorio local de evidencia, cada run W&B local y cada archivo experimental indexable. La salida no reemplaza la interpretación causal; fija el inventario de lo que existe y obliga a ubicar incluso las ramas que no dejaron un resultado final comparable.

Las figuras siguen un criterio editorial simple: el lienzo del gráfico se reserva para datos, ejes, leyendas, umbrales y anotaciones numéricas. La interpretación de cada resultado aparece en la leyenda y en el texto que acompaña a la figura, no como un título incrustado dentro del gráfico.

Tabla 2: Cómo se interpreta una corrida en este informe.

Artefacto	Qué fija	Riesgo si se omite
<code>config.json</code> o <code>experiments/*.json</code> <code>metrics.jsonl</code>	Tamaño, fuentes, comida, hormigas, bits, radio, crítico, horizonte, rewards y modo de transferencia. Evolución por update: entregas, pickups, cobertura, bytes, entropía, KL, gradientes y pérdidas.	Comparar corridas que no tienen el mismo contrato. Confundir un pico, una caída o una métrica moldeada con desempeño final.
<code>summary.json</code>	Estado final y, cuando existe, métricas del mejor checkpoint.	Mezclar último checkpoint con checkpoint seleccionado.
Videos locales / W&B	Comportamiento visible: búsqueda, recogida, regreso al hub, saturación de bytes o movimiento sin entrega.	Usar un video vistoso como sustituto de eventos reales.

4. Resultados experimentales

4.1. Cambio de contrato de la tarea

El primer cambio grande fue conceptual. La tarea dejó de premiar fuertemente recoger comida y pasó a medir entregas al hub con fuentes agotables. Esto convirtió el problema en foraging real: encontrar no basta, hay que cerrar el ciclo fuente-hub. También hizo que la densidad de fuentes fuera una variable de dificultad.

Esta frontera invalida comparaciones ingenuas con corridas viejas. Un reward alto bajo pickup reward no significa lo mismo que un reward alto bajo delivery-only reward.

4.2. Primer enfoque: mapas cada vez más grandes

La primera línea JAX intentó resolver el problema como un currículo de tamaño: entrenar en mapas chicos y aumentar progresivamente hasta 50x50. El contrato de `forage_curriculum.json` era una hormiga, radio local 1, 48 unidades de comida repartidas en 12 fuentes, 1 bit de escritura, 10000 pasos máximos, `hidden_size=128` y etapas explícitas de 4x4 a 50x50. Era una idea razonable: si la política aprende el ciclo fuente-hub en chico, tal vez pueda transferirlo a mapas más grandes.

No alcanzó. El reporte consolidado local registra que el retorno bajaba de 12,281 en 4x4 a 0,719 en 25x25 y 0,156 en 50x50. El patrón observado era compatible con agentes que exploran o cargan comida, pero no convierten eso en ciclos repetidos de entrega.

También quedó preservada una secuencia posterior de checkpoints de tamaño, de 8x8 a 50x50, con 4 hormigas, 1 bit, radio 1 y observación 50x50. Esa secuencia visual es útil porque muestra el contrato experimental creciendo, no porque resuelva la frontera. En esa corrida, el mejor punto evaluado llegó a 22,5/48 y 0,9 entregas por 1000 pasos-hormiga, pero la familia volvió a oscilar y no quedó como solución robusta. La causa más plausible no fue falta de bits. Era una mezcla de horizonte largo, recompensa escasa, cobertura insuficiente y crédito débil.

4.3. El desbloqueo 25x25

El primer resultado fuerte aparece al combinar moldeado de distancia, más hormigas y más capacidad. `DISTANCE_SHAPE` ya hacía parcialmente aprendible el umbral 25x25: 13,75/23 en greedy, pero solo 7/23 muestreado. `DISTANCE_CAP4` cambia a cuatro hormigas y hidden size

Tabla 3: Cobertura del ledger de auditoría usado para actualizar el árbol.

Superficie auditada	Cantidad	Qué significa para la lectura
Commits alcanzables	334	Historia completa visible desde refs locales y remotos.
Refs visibles	13	Incluye ramas fusionadas, rama del sitio e investigaciones no fusionadas.
Cambios path-level	1651	Permite ubicar cada cambio de archivo dentro de una familia experimental.
Configs experiments/*.json	25	Contratos explícitos de entrenamiento y evaluación.
Notebooks	17	Superficies de lanzamiento, análisis, videos y exploración.
Directorios de runs	145	Evidencia local con summaries, métricas, evals, planes o configs.
Runs W&B locales	230	Carpetas locales indexadas; el API cloud quedó bloqueado por <code>reloginrequired</code> .
Logs	9	Registros operacionales preservados.
Archivos indexados	7771	Superficie del checkout fuera de <code>.git</code> , entornos locales y la propia salida de auditoría.

mayor; allí la evaluación muestreada llega a 23/23 con éxito 1,0, aunque el modo greedy cae a 2,75/23.

El resultado `DISTANCE_CAP4_NO_WRITE` es una advertencia contra sobreinterpretar comunicación: incluso sin escritura, una continuación entrega 22/23 bajo movimiento muestreado. No es una ablación perfectamente controlada, porque también cambian schedule y optimizador, pero sí muestra que la solución 25x25 no requiere demostrar comunicación por bytes.

Las continuaciones de 25x25 muestran que el problema no era un solo interruptor. `DISTANCE_CAP4_SHARP` mejora greedy a 13/23, pero baja el resultado muestreado a 20,5/23. La continuación long-credit recupera el 23/23 muestreado, aunque deja greedy en 11/23. La variante gentle-greedy sube greedy a 14,75/23 y conserva el 23/23 muestreado. `DISTANCE_VISION2_CAP4` también logra 23/23 muestreado con radio 2, pero cambia observación y capacidad. La lectura no es que una ablación aislada resolvió todo; es que shaping, cobertura, capacidad y modo de despliegue formaron un paquete aprendible.

4.4. Bits contra cobertura

Los barridos tempranos de bits no muestran un salto claro de capacidad. En una línea 15x15 aproximada, el retorno de entrenamiento sube de 6,40 a 7,36 al pasar de 2 a 5 bits y luego baja levemente en 8 bits. En la línea anclada a 25x25, el retorno se mantiene bajo. En cambio, aumentar el número de hormigas en 25x25 con 3 bits produce una mejora monotonía de retorno de episodio: 7,7875 con 2 hormigas, 10,6987 con 3, 12,545 con 4, 16,1287 con 6 y 18,2294 con 8.

4.5. Métricas registradas más allá del retorno final

Las corridas locales y los resúmenes W&B no registraban solo reward final. En varias ramas se guardaron `delivery_events`, `pickup_events`, `mean_carrying_ants`, cobertura visitada, fracción de bytes no-cero, tasa de escritura, entropía, `approx_kl`, norma de gradiente, `value_loss` y, cuando había evaluación, comida entregada por 1000 pasos-hormiga. Esa instrumentación es parte de la historia: permitió detectar políticas que exploraban casi todo el mapa, escribían mucho o cargaban comida, pero no necesariamente entregaban.

Tabla 4: Familias del árbol completo. La columna “ubicación” indica cómo deben aparecer en el sitio y en la lectura del informe, no una afirmación causal.

Familia	Evidencia	Ubicación en el árbol
foundation-task-contract	8 commits, 11 archivos	Nacimiento del entorno: sprites, reset, fuentes agotables, entrega y rollout aleatorio.
jax-mappo-training-core	21 commits, 155 archivos, 13 W&B locales	JAX, MAPPO, trainer, eval, checkpoints, recursos y ramas multi-device.
autocurriculum-exploration-baselines	29 commits, 4 configs, 4 notebooks	Forage/exploration/autocurrículos tempranos y lanzadores base.
communication-memory-bytes	94 commits, 10 runs, 27 W&B locales	Bits, memoria externa, write-head, no-write, write-cost y R8-R12.
ant-count-25x25-autoresearch	75 commits, 52 runs	Desbloqueo 25x25 por distancia, cobertura, cantidad de hormigas, CAP y visión.
source-layout-50x50	4 commits, 4 configs, 4 notebooks	Fuente sparse 50x50: padded, proximity, smooth, rare, vectores y previews.
critic-full-layout-50x50	29 commits, 6 configs, 3 runs	Cambio a crítico espacial, full-layout, shared writes, costo y continuaciones 8-ant.
sixty-ant-50x50-stabilization	6 commits, 4 configs, 1 notebook	Frontera 50x50 con 60 hormigas, 8 bits, identidad y estabilización.
hundred-bridge-maze-stress	16 commits, 16 runs, 173 W&B locales	Puente 100x100, laberinto entrenado como exploración y stress maze 100x100.
twofifty-frontier-reset	15 commits, 25 runs, 11 W&B locales	250x250, half-scale, resnet/set critics, reset-boundary, truncación y distancia.
bigmap-deployment-rendering	10 commits, 6 runs	Render y despliegue solo-actor grande: 1000x1000, paletas y sandbox JS.
adversarial-roles-side-branches	14 commits	Frozen-opponent, timed-release roles y probes visibles solo por branch.
report-site-paper-assets	8 commits, 65 archivos	Informe, sitio, plots, videos, posters, planificación y figuras generadas.
infra-tests-ci-cleanup	3 commits, 522 archivos, 31 runs	Tests, CI, packaging, limpieza de almacenamiento y soporte no experimental.
curated-results-and-vault	4 archivos	Índices curados y placeholders de vault; evidencia retenida, no experimento nuevo.
unclassified-review-needed	2 commits	Bucket explícito para evidencia que no debe usarse en el paper sin inspección manual.

Tabla 5: Refs visibles que fijan ramas del árbol. Las ramas no fusionadas se documentan como evidencia o dirección exploratoria, no como resultados comparables salvo que tengan métricas preservadas.

Ref	Familia	Lectura
main, origin/main, origin/HEAD	critic-full-layout-50x50	Base remota fusionada con la línea de crítico/full-layout 50x50.
report-writing-site, origin/report-writing-site	report-site-paper-assets	Rama actual del informe, sitio, videos, plots y árbol narrativo.
feat/multi-device-jax-mappo, origin/feat/multi-device-jax-mappo	jax-mappo-training-core	Rendimiento/multi-device y experimentos x150/write-cost; no se lee como resultado principal.
train-half-scale-resnet	twofifty-frontier-reset	Lanzamiento half-scale resnet 250x250: dirección de escala, no resultado final comparable.
origin/lethal_cookies	hundred-bridge-maze-stress	Arena en L, laberinto/proximidad y bolsillos letales; sin métricas locales finales comparables.
origin/research/ adversarial-marl-experiments	adversarial-roles-side-branches	Frozen-opponent y roles adversariales documentados como probes laterales.
origin/research/timed-release-roles	adversarial-roles-side-branches	Continuación parked de roles cooperativos con liberación temporal.
origin/vision_shrink_curriculum	ant-count-25x25-autoresearch	Continuación CAP/visión de 25x25; pertenece al árbol de cobertura, no a la frontera 50x50.
origin/repo/ research-integration-cleanup	jax-mappo-training-core	Integración, tests y limpieza de soporte; relevante para reproducibilidad.




Figura 2: Evaluación 25x25 bajo dos protocolos de despliegue. Cada barra muestra la fracción de comida entregada y anota entregas sobre 23 unidades. La línea punteada marca la tarea completa: el resultado importante es la brecha entre movimiento greedy y movimiento muestreado, no solo el máximo alcanzado.

En la línea 50x50 larga, por ejemplo, la cobertura final sube desde 0,059 al principio hasta 0,9275 hacia el final, mientras la tasa de escritura no-cero baja desde 0,113 hasta 0,0168. En la línea eficiente 50x50, los logs de evaluación registran eficiencia: una evaluación temprana dio 13,5 entregas y 0,54 entregas por 1000 pasos-hormiga; otra alcanzó 18,0 y 0,72, aunque más tarde esa familia volvió a oscilar. Estos números explican por qué el informe no debe contar solo el mejor video.

4.6. Autocurriculum por tamaño activo

La inspiración era el autocurriculum de locomoción de Rudin et al. en ETH Zurich [3]. Allí el robot ANYmal no empieza resolviendo directamente los terrenos más difíciles. Miles de robots simulados se distribuyen por tipo de terreno y nivel de dificultad: plano, pendientes, rugosidad, obstáculos y escaleras. Si un robot cruza su terreno, en el siguiente reset sube de nivel; si no avanza lo suficiente, baja. En escaleras y obstáculos aumenta la altura del escalón, y en pendientes aumenta la inclinación. La idea útil para este proyecto era esa regla de control de dificultad: mantener al agente cerca de una frontera aprendible y endurecer el entorno solo cuando el comportamiento actual ya domina la etapa.

Nuestro autocurriculum por tamaño activo aplicó esa idea a una grilla 50x50 acolchada. La observación conservaba el formato final, pero el área jugable empezaba en 4x4 y crecía de a una celda por lado después de seis entregas en la etapa. El contrato relevante era una política de una hormiga, 12 unidades de comida, 2 fuentes, 1 bit de escritura, radio de visión 1, crítico `mlp`, `pickup_bonus=0.25` y sin moldeado de distancia. El objetivo era evitar entrenar una política distinta por tamaño: primero cerrar el ciclo fuente-hub en pequeño, después exigir el mismo ciclo en regiones cada vez más grandes hasta 50x50.

La reproducción de verificación en Google Cloud, resumida en `autocurriculum_active_size_gcloud.csv` y sincronizada a W&B como `e5ymgvil`, confirma que la idea avanzaba etapas pero no cerraba el problema. El run completó 1,28 millones de pasos con `metrics.jsonl`, `summary.json` y checkpoint final. La mejor ventana observada llegó a 6 etapas completadas y tamaño activo máximo 19; el resumen final quedó en `autocurriculum_max_active_size=19`, `autocurriculum_completed_stages=3`, `delivery_events=5`, `pickup_events=6` y `episode_return=0.40625`. Es decir, el umbral por entregas sí podía empujar el curriculum fuera del 4x4




Figura 3: Comparación entre dos hipótesis tempranas. El panel izquierdo muestra retornos de entrenamiento al variar la cantidad de bits de escritura; el panel derecho muestra retornos al variar la cantidad de hormigas. La lectura favorece una explicación de cobertura multi-agente antes que una explicación basada solo en aumentar el alfabeto de escritura. Estas curvas no son evaluaciones held-out.

inicial, pero la política no transfería el ciclo de foraging hasta 50x50 bajo una sola hormiga, radio local 1 y crítico plano. La rama queda como evidencia negativa temprana: el aumento automático de dificultad no reemplazó al moldeado de distancia, la cobertura por más agentes ni el cambio posterior a críticos espaciales.

4.7. Laberintos: entrenamiento exploratorio sin foraging comparable

Otra rama exploró laberintos. En la rama actual queda el config `maze_exploration_curriculum.json`: laberintos generados de 10x10 a 50x50, una hormiga, 48 unidades de comida, 12 fuentes, 2 bits, radio 1, crítico MLP, `max_steps=6250`, 16 entornos por 80 pasos, `reward_mode=explore`, pasillos de ancho 3, paredes de ancho 1 y semilla 17. La infraestructura de obstáculos sí quedó implementada y testeada: obstáculos bloquean movimiento, aparecen en observaciones, los resets ubican hub/comida/hormigas en celdas abiertas y los layouts pueden cambiar tras truncación.

También existió una rama lateral `origin/lethal_cookies`. Allí el cuaderno de maze preparaba una prueba de estrés 41x41 en forma de L dentro de una arena 50x50, con pasillos de ancho 5, 20 hormigas, una fuente normal al final y, en una variante hermana, bolsillos laterales para fuentes letales. Sin embargo, esa rama no tiene en el checkout actual métricas locales preservadas de entrega, supervivencia, eficiencia o convergencia, y la llamada de entrenamiento del cuaderno de maze estaba comentada.

Para el sitio web se recuperó el video correcto desde W&B, correspondiente al run terminado `8ebnjq9f` y a la clave `videos/maze_exploration/50x50`. Ese artefacto sí viene de la política entrenada para laberintos: 50x50, una hormiga, 48 unidades de comida, 12 fuentes, 2 bits, radio 1, `reward_mode=explore`, pasillos de ancho 3, paredes de ancho 1 y semilla 17. El MP4 tiene 600 fotogramas, 800 × 800 píxeles, 8 fps y 75 segundos. El summary final reporta `episode_return=26.125`, `final_mean_remaining_food=45.5/48` y `completed_episodes=0`. La colección de modelos recuperable conserva checkpoints de laberinto hasta `jax_mappo_maze_explore_24x24.pkl`; para la etapa 50x50 quedó preservado el video, no el checkpoint local.

Después del cierre inicial del sitio se agregó una prueba de estrés no entrenada para laberinto: el actor estabilizado 50x50 de 60 hormigas se desplegó como solo-actor en un laberinto 100x100 con una sola fuente lejana. Se usó `sampled_move_greedy_write`, temperatura de movimiento 0,525 y escritura greedy. El hub quedó en [6, 5], la fuente efectiva en [81, 70], y en el layout




Figura 4: Métricas registradas en logs locales de dos ramas 50x50. Los paneles separan eventos de tarea, evaluación held-out, cobertura/escritura y señales de optimización. La figura no reemplaza las tablas finales: muestra por qué el análisis necesita más dimensiones que retorno final o apariencia visual.

seleccionado la distancia por pasillos fue 172. Las paredes sí entraron al actor por el mismo canal local de borde/obstáculo. Aun así, en 60000 pasos no hubo recogidas ni entregas: 0/125 entregado, 125/125 restante, 887 celdas visitadas y 886 celdas con bytes no-cero. Esta prueba no contradice el video entrenado de W&B; muestra que el actor abierto de 60 hormigas no transfiere directamente a paredes internas aunque pueda observarlas.

Por eso el laberinto debe contarse como rama entrenada de exploración, no como resultado comparable de foraging cooperativo. La prueba 100x100 debe contarse como fallo de transferencia solo-actor, no como fallo de percepción de paredes. La infraestructura de obstáculos funcionó y produjo evidencia visual, pero el contrato entrenado de laberinto no medía entrega; la decisión experimental fue volver al foraging abierto, donde sí existían curvas, videos, puntos guardados y métricas de comida recolectada.

4.8. Memoria y autoresearch: escribir no basta

La línea de memoria intentó convertir la observación cualitativa de bytes escritos en una afirmación causal. El criterio correcto era más exigente: una política con bytes debía superar pruebas `no_byte_read` y `no_write`, y al mismo tiempo mantener o mejorar comida entregada. Los barridos R8-R12 y las recompensas `delivery_byte_trail_bonus`, `byte_follow_bonus` y variantes relacionadas fueron diseñados para esa pregunta.

La conclusión no fue positiva. El punto guardado sparse apenas dependía de los bytes. R8 entregó bien pero no a través de memoria: `normal`=394, `no_byte_read`=397 y `no_write`=397. R9 produjo una brecha más causal, pero dañó el foraging: `normal`=124 contra ablaciones de 56. R10 fue más liviano, aunque todavía débil: 260 contra 248. R11 preservó conducta sparse sin ganancia causal: 378 contra 395 y 395. R12 quedó interrumpido antes de un resultado final confiable. Junto con el resultado `DISTANCE_CAP4_NO_WRITE` de 22/23, esto impide afirmar que la memoria externa causó los mejores resultados. Lo que sí queda demostrado es más modesto: el entorno ofrece una memoria discreta y las políticas pueden escribirla; falta probar que esa




Figura 5: Layout 50x50 generado desde `maze_exploration_curriculum.json` con el generador real de laberintos del entorno. Esta figura muestra la geometría; el sitio web complementa con el video W&B 50x50 del currículo entrenado.

información escrita mejore decisiones de forma robusta.

4.9. Fuentes cada vez más dispersas

Otra línea importante no escalaba por tamaño de mapa, sino por geometría de comida. La hipótesis era que el cuello de botella podía ser descubrimiento de fuentes: si la comida empieza fácil de encontrar y luego se vuelve escasa, quizá la política aprenda búsqueda y explotación sin depender tanto de ayudas de distancia.

Hubo varias formas de probarlo. `exploration_to_forage_padded_sources_50x50` mantuvo una arena 50x50 por compatibilidad de checkpoint, restringió hub y comida a una ventana interior 20x20, partió de un checkpoint 20x20 y redujo posiciones de fuente de 12 a 2 con 18 unidades totales. Esa forma fue débil: alrededor de 0,25/18. `exploration_to_forage_scratch_smooth_sources_50x50` fue más ambiciosa: arena exterior 80x80, ventana interior 50x50, 250 unidades de comida, 4 bits y annealing suave de posiciones de fuente desde 250 hasta 2. No quedó como resultado principal. `exploration_to_forage_proximity_sources_50x50` cambió la idea: mantener dos macro-fuentes desde el inicio, pero empezar con footprints cercanos y reducirlos hasta dos celdas finales dentro de una ventana interior 30x30.

El resultado de proximidad llegó a 40,875/250, pero no debe leerse aislado: esa rama también introduce el crítico espacial `strided_cnn`. Por eso el currículo de fuentes dispersas es una pieza de la historia, no una conclusión causal cerrada. Mostró que descubrimiento de comida y




Figura 6: Pruebas de memoria R8–R11. Cada grupo compara la evaluación normal contra dos ablaciones: impedir la lectura de bytes y bloquear la escritura. R12 queda fuera de la figura porque se interrumpió antes de un resultado final confiable. La lectura importante no es cuántos bytes aparecen, sino si la política mantiene foraging y mejora frente a las ablaciones.

representación espacial del crítico eran cuellos distintos.

Tabla 6: Currículos de tamaño y de fuentes dispersas.

Rama	Contrato	Lectura
<code>forage_curriculum</code>	1 hormiga, 4x4–50x50, 48 comidas, 12 fuentes, 1 bit.	Primer enfoque por mapas crecientes; colapsa al crecer.
<code>autocurriculum</code>	cuadrado activo 4x4–50x50, avance tras 6 entregas por etapa, 12 comidas en 2 fuentes.	Avanza etapas, pero no produce competencia transferible robusta.
<code>padded_sources</code>	50x50 oculto, ventana interior 20x20, posiciones de fuente 12–2, 18 comidas.	Resultado débil, cerca de 0,25/18.
<code>smooth_sources</code>	80x80 exterior, 50x50 interior, 250 comidas, posiciones 250–2.	Prueba de annealing suave; no queda como resultado principal.
<code>proximity_sources</code>	50x50 exterior, 30x30 interior, 4 hormigas, 250 comidas, dos macro-fuentes con footprint decreciente.	40,875/250, mezclado con <code>strided_cnn</code> .

4.10. Ablaciones y diagnósticos que cambiaron la interpretación

No todas las ramas fueron resultados principales, pero varias cambiaron qué se podía afirmar. La regla de lectura fue conservadora: cuando una corrida cambia muchas cosas a la vez, se cuenta como intervención; cuando compara una política contra una versión `no_write`, `no_byte_read` o un costo equivalente, se acerca más a una ablación causal.

Tabla 7: Diagnósticos que evitaron sobreinterpretar el resultado principal.

Diagnóstico	Cambio	Número clave	Lectura
DISTANCE_CAP4_NO_WRITE	25x25 sin escritura.	muestreado 22/23, éxito 0,5.	La política 25x25 no necesita demostrar comunicación por bytes para explicar el solve muestreado.
R8-R12 memoria	normal contra no_byte_read y no_write .	R8 394/397/397; R9 124/56/56.	La dependencia causal aparece cuando el foraging empeora; no prueba una memoria útil y robusta.
Escritura compartida y costo	8 hormigas 50x50 con escritura compartida y penalización.	45,25/125 a 69,375/125.	Progreso práctico en el linaje strided_cnn , no ablación aislada.
Sondeo de comunicación	Evaluación del checkpoint con costo de escritura.	determinista 18,5/125, muestreado 22,25/125.	Los bytes existen, pero la lectura causal sigue débil.
Costo de escritura x300 / 6 fuentes	Costo severo y fuentes más numerosas.	primer eval 68,375/125, final 19,625/125.	Reducir escritura puede degradar la política si el contrato cambia demasiado.
250x250 trunc4096	Continuación desde frontera con horizonte truncado.	mejor train 685, final 13.	Hubo picos, pero no estabilidad final.
Directa / exploración / laberinto	Líneas base e infraestructura lateral.	video W&B 50x50; prueba 100x100: 0 recogidas, 0 entregas.	La rama entrenada era exploración; la prueba solo-actor muestra no-transferencia al laberinto.

4.11. 50x50 raro y ayudas vectoriales

Cuando la comida se vuelve rara en 50x50, el problema cambia. El agente debe descubrir fuentes con baja probabilidad y luego sostener ciclos. La línea base rara llega a 10,96/23. Agregar visión de radio 2 no ayuda. Agregar vector al hub mejora poco. Agregar vector al hub y a la comida cercana sube a 15,20/23, y selección held-out llega a 16,20/23 en la confirmación final. La rama posterior de radio de spawn fue inconclusa, no negativa: completó **spawn8** con retorno de entrenamiento 5.898, **spawn16** con 7.209 y se detuvo en 130/500 actualizaciones de la etapa final sin **summary.json**.

4.12. La frontera del crítico en 50x50

La línea 50x50 eficiente inicial usa el crítico MLP por defecto y entrega 21,5/48. La línea posterior de proximidad y full-layout cambia a **strided_cnn**. Ese cambio es mayor: el crítico ya no procesa una observación central plana, sino una representación espacial. Dentro de esa familia aparecen mejoras importantes, pero también colapsos de checkpoint y fuerte dependencia de selección.

El mejor resultado local de 8 hormigas en esa familia es **shared_writes_write_cost_from_shared_best**: 69,375/125, éxito 0,125. Es progreso real, pero no una solución completa. También tiene escritura no-cero muy alta, alrededor de 0,94, por lo que no alcanza para afirmar que haya un código compacto e interpretable.

La línea reciente de 60 hormigas es la frontera actual del repo. Una evaluación de 64 episodios del punto guardado estabilizado reporta 123,90625/125, fracción 0,99125, éxito 0,90625. Esto es fuerte como ingeniería de comportamiento 50x50, pero cambia demasiadas cosas a la vez: 60 hormigas, 8 bits, actor con identidades repetidas, continuación desde un punto guardado, crítico **strided_cnn**, selección por evaluación, temperaturas y escritura casi saturada. Debe presentarse como resultado prometedor, no como prueba causal de comunicación.




Figura 7: Evaluaciones seleccionadas en el escenario 50x50 con fuentes raras. Las barras reportan fracción entregada y anotan entregas sobre 23 junto con tasa de éxito. Las ayudas vectoriales parecen facilitar descubrimiento, pero la mejora no prueba comunicación emergente porque las corridas cambian más de una variable.

4.13. 250x250: la trampa del retorno moldeado

La escala 250x250 mostró el fracaso más informativo. Corridas con `resnet_cnn` o `strided_cnn` en una fuente terminan con cero pickups y cero entregas. En la familia `set_cnn`, el autocurriculo de distancia puede producir retorno positivo de moldeado, muchos agentes cargando y mapas de bytes saturados, pero todavía cero entregas finales. Es exactamente el tipo de resultado que un informe debe separar de la métrica objetivo.

El cambio `fixed8-reset-boundary256` sí mejora la entrega local: el resumen final tiene 654 entregas y 869 pickups, y el mejor tramo de entrenamiento llega a alrededor de 1003 entregas. La evaluación `fresh-window` del mismo linaje selecciona `reset_boundary_final` como campeón por mediana de entregas. Aun así, esto no resuelve la escala general. Es una intervención de reset y distancia dentro de una familia de crítico distinta.

Las continuaciones posteriores refuerzan esa lectura. `byte-decay` redujo ocupación de bytes pero terminó con 175 entregas. La evaluación larga `d12` de la rama `no-decay` mostró una media de 0.392 entregas, mediana 0, `pickup_to_delivery_rate`=0.008 y 13.745 pickups no entregados en promedio. El intento estratificado `d4/d8/d12` dejó manifiesto y configuración, pero los archivos `metrics.jsonl`, `fresh_eval_metrics.jsonl` y `long_eval_metrics.jsonl` quedaron vacíos después de un aborto operacional tipo `exit 137`. No es evidencia contra la hipótesis; simplemente no produjo un resultado interpretable.

5. Evidencia cualitativa

Los videos apoyan una lectura progresiva. Primero hay movimiento local sin retorno estable. Después, los rollouts preservados del currículo 25x25 muestran cómo cambia el comportamiento al pasar por 2, 3, 4, 6 y 8 hormigas: la cobertura deja de ser un detalle y se vuelve parte del mecanismo. En 50x50 con crítico espacial aparecen rutas repetidas y entregas más densas. Las visualizaciones grandes deben leerse con cuidado: 100x100 es una continuación seleccionada, 250x250 muestra una recuperación local por `reset-boundary`, y 1000x1000 es un despliegue solo-actor de una política ya entrenada, no entrenamiento de punta a punta en ese entorno. La prueba 100x100 de laberinto agrega una evidencia negativa visualmente útil: hay exploración local y escritura de bytes, pero no aparece el ciclo recogida-retorno que define el foraging.




Figura 8: Resultados 50x50 seleccionados con denominadores explícitos en cada barra. La línea vertical marca el cambio de crítico MLP a crítico espacial. Las barras posteriores no son una sola ablación: combinan arquitectura del crítico, geometría de fuentes, cantidad de hormigas, escritura, costos y selección de checkpoints.

6. Discusión

La evidencia más fuerte apunta a cinco decisiones que sí cambiaron el problema de manera productiva. La primera fue redefinir la tarea alrededor de entregas reales y fuentes agotables; sin esa frontera, una política podía parecer activa sin cerrar ciclos de foraging. La segunda fue usar moldeado de distancia para atravesar el horizonte largo inicial, especialmente en 25x25. La tercera fue aumentar la cobertura mediante más hormigas, un cambio que tuvo más efecto práctico que aumentar simplemente la cantidad de bits. La cuarta fue evaluar políticas con movimiento muestreado cuando el comportamiento aprendido vivía en la distribución y no en el argmax. La quinta, crucial para 50x50, fue reemplazar el crítico centralizado plano por una arquitectura espacial.

Otros resultados son útiles, pero tienen confusión causal. La escritura compartida y las penalizaciones de escritura mejoraron algunas continuaciones 50x50, aunque no aislaron el rol de los bytes. El aumento a 8 bits tampoco es una ablación limpia, porque cambió junto con costos, cantidad de hormigas y selección de checkpoints. La línea de 60 hormigas es el resultado conductual más fuerte, pero mezcla 60 agentes, identidades repetidas, 8 bits, continuación desde un punto guardado, crítico `strided_cnn`, selección por evaluación y escritura casi saturada. En 250x250, `reset-boundary` arregla ventanas locales de entrenamiento, pero no demuestra que el autocurrículo general de gran escala haya quedado resuelto.

La evidencia negativa es igual de importante para la interpretación. Aumentar bits no funcionó como mecanismo único de escala. El autocurrículo por tamaño activo podía avanzar etapas sin llegar a 50x50, y en 250x250 el retorno moldeado podía crecer aunque las entregas reales siguieran siendo nulas. El flujo de laberintos produjo un video entrenado de exploración 50x50 y una prueba de estrés 100x100, pero no una demostración comparable de foraging cooperativo en laberinto. Las ramas R8–R12 mostraron que puede haber dependencia de bytes, pero no una mejora robusta de tarea causada por memoria externa. Las ramas adversariales, timed-release y lethal-cookies quedan ubicadas en el árbol por refs, commits e infraestructura, aunque no tienen el mismo paquete de métricas, videos y evaluaciones que las líneas centrales.

Por estas razones, el informe evita tres sobreinterpretaciones. El despliegue determinista no se usa como único criterio de éxito cuando la política aprendida es estocástica. El retorno moldeado no se trata como sustituto de entrega real. Y la comunicación emergente no se afirma




Figura 9: Diagnóstico 250x250 separado por métrica. El panel izquierdo muestra eventos reales de tarea, entregas y pickups. El panel derecho muestra actividad de escritura y fracción de bytes no-cero. La comparación deja visible la lección negativa: el retorno moldeado y la actividad de bytes pueden crecer sin resolver entrega; reset-boundary recupera progreso local de entrega.

sin ablaciones emparejadas, como `no_write`, bytes permutados, costos igualados entre alfabetos y comparaciones de crítico bajo el mismo contrato de entorno.

7. Limitaciones

La limitación principal es experimental: muchas corridas son continuaciones con varios cambios simultáneos. Por eso este informe habla de “intervenciones” y no de ablaciones puras salvo donde haya evidencia comparable. También hay diferencias entre punto guardado final, mejor punto guardado, selección held-out y resúmenes W&B. Esas diferencias importan porque varias corridas tienen pico temprano y luego degradación.

La segunda limitación es semántica. La memoria externa existe y se usa en el sentido de que hay acciones de escritura y bytes no-cero. Pero todavía falta demostrar que la información escrita cause mejores decisiones. Para eso hacen falta evaluaciones como: congelar política y borrar bytes, permutar bytes entre celdas, bloquear escritura solo en test, igualar costos entre 4 y 8 bits, y comparar `mlp` contra `strided_cnn` con el mismo entorno.

La tercera limitación es de escala. El resultado 60-ant 50x50 es muy bueno, pero usa muchos agentes y escritura saturada. Puede ser la dirección de ingeniería correcta, pero no responde por sí solo la pregunta de comunicación compacta.

La cuarta limitación es de trazabilidad negativa. Algunas ramas importantes, como laberintos, lethal-cookies, roles adversariales, timed-release, multi-device/write-cost y cuadernos laterales de prueba de estrés, quedaron mejor representadas por código, commits, refs, videos diagnósticos y metadatos que por evaluaciones finales comparables. En este informe se incluyen porque explican decisiones del proyecto, pero no se usan como evidencia cuantitativa de desempeño. El video W&B de laberinto y la prueba 100x100 muestran comportamiento, no una métrica de foraging cooperativo resuelta.

8. Conclusión

El proyecto produjo una historia clara. Primero hubo que corregir la semántica de la tarea: entregar comida, no solo encontrarla. Luego hubo que hacer aprendible el crédito: moldeado de distancia, más agentes y despliegue muestreado. Después apareció el detalle más importante para 50x50: el crítico centralizado espacial. Ese cambio reestructura el aprendizaje y debe figurar

como una causa mayor. La memoria por bytes sigue siendo una hipótesis interesante, no una conclusión demostrada.

La contribución honesta del trabajo no es “resolvimos comunicación emergente”. Es más precisa: construimos un entorno de foraging multi-agente con memoria externa, identificamos qué cambios desbloquean cada escala, alcanzamos solución robusta en 25x25 y resultados muy fuertes en 50x50 bajo crítico espacial, mostramos que en 250x250 el retorno moldeado puede engañar si no se mide entrega real, y dejamos un árbol auditado donde también figuran las ramas que fallaron, quedaron incompletas o solo sobreviven como infraestructura experimental.

A. Trabajo futuro

El informe cierra la historia experimental disponible en el checkout actual, pero varias extensiones convertirían las lecturas principales en evidencia causal más fuerte. La primera prioridad es congelar una tabla canónica de runs y checkpoints por familia, acompañada por hiperparámetros comparables: `critic_architecture`, `food_count`, `food_sources`, cantidad de hormigas, bits, modo de evaluación y criterio de selección. Esa tabla evitaría que los resultados dependan de nombres de corrida o de memoria contextual.

La segunda prioridad es completar la trazabilidad externa. La auditoría actual garantiza exhaustividad local, pero la tabla cloud de W&B debería regenerarse después de `wandbrelogin`. También conviene inspeccionar manualmente el bucket `unclassified-review-needed` antes de usarlo como evidencia en un paper o presentación.

La tercera prioridad es ejecutar ablaciones emparejadas para memoria. Una prueba mínima debería comparar la misma política bajo escritura normal, escritura bloqueada, lectura bloqueada, bytes permutados entre celdas y costos igualados entre alfabetos de 4 y 8 bits. Si se quiere convertir los laberintos en una línea principal, el contrato también debe cambiar: no basta un video de exploración, sino que hace falta una plantilla comparable con recogidas, entregas, eficiencia, tiempo de convergencia, 60 hormigas y una fuente lejana bajo el mismo criterio de evaluación.

Referencias

- [1] Jakob Foerster, Ioannis Alexandros Assael, Nando de Freitas, and Shimon Whiteson. Learning to communicate with deep multi-agent reinforcement learning. In *Advances in Neural Information Processing Systems*, 2016.
- [2] Ryan Lowe, Yi Wu, Aviv Tamar, Jean Harb, Pieter Abbeel, and Igor Mordatch. Multi-agent actor-critic for mixed cooperative-competitive environments. In *Advances in Neural Information Processing Systems*, 2017.
- [3] Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning. In *Proceedings of the 5th Conference on Robot Learning*, volume 164 of *Proceedings of Machine Learning Research*, pages 91–100. PMLR, 2022.
- [4] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation, 2015.
- [5] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms, 2017.
- [6] Sainbayar Sukhbaatar, Arthur Szlam, and Rob Fergus. Learning multiagent communication with backpropagation. In *Advances in Neural Information Processing Systems*, 2016.

- [7] Chao Yu, Akash Velu, Eugene Vinitzky, Jiaxuan Gao, Yu Wang, Alexandre Bayen, and Yi Wu. The surprising effectiveness of ppo in cooperative multi-agent games. In *Advances in Neural Information Processing Systems*, 2022.




Figura 10: Fotogramas extraídos de videos locales. A: línea base aleatoria. B–F: progresión visual del currículo 25x25 con 2, 3, 4, 6 y 8 hormigas. G: frontera 50x50 con 60 hormigas. H: despliegue solo-actor 1000x1000 de la política 50x50. La figura no es evidencia cuantitativa; sirve para interpretar la semántica visual de las métricas.